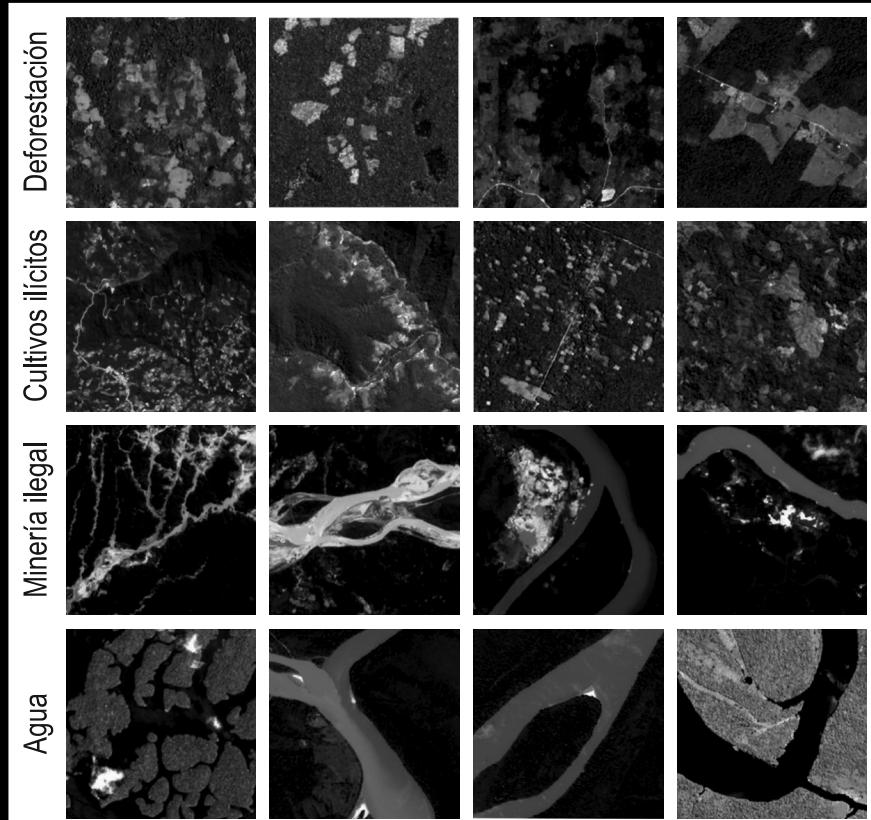


Revista de TELEDETECCIÓN

Nº 59 | Enero 2022

Revista de la Asociación Española de Teledetección



ASOCIACIÓN
ESPAÑOLA
DE TELEDETECCIÓN



**Revista de
TELEDETECCIÓN**

No.59 | Enero 2022

Revista de la Asociación Española de Teledetección



REVISTA DE TELEDETECCIÓN

<http://polipapers.upv.es/index.php/raet>

DIRECTOR

Luis Ángel Ruiz Fernández

Dpto. de Ingeniería Cartográfica, Geodesia y Fotogrametría.
Universitat Politècnica de València
Camino de Vera s/n, 46022 – Valencia.
Tel.: 963 877 550 (director.revista@aet.org.es)

SECRETARIO

Javier Estornell Cremades

Dpto. de Ingeniería Cartográfica, Geodesia y Fotogrametría.
Escuela Politécnica Superior de Gandia
Universitat Politècnica de València
C/ Paraninfo, 1, 46730 – Grau de Gandia (Valencia).
Tel.: 962849324 (jaescre@cfg.upv.es)

CONSEJO DE REDACCIÓN

Mª Amparo Gilabert, Universitat de València, España
Consuelo Gonzalo, Universidad Politécnica de Madrid, España
Christian Heipke, Leibniz Universität Hannover, Alemania
Massimo Menenti, Delft University of Technology, Países Bajos
L. Monika Moskal, University of Washington, EE.UU.
Antonio J. Plaza, Universidad de Extremadura, España
Xavier Pons, Universitat Autònoma de Barcelona, España
Francisco J. Tapiador, Universidad de Castilla La Mancha, España
Pablo J. Zarco-Tejada, CSIC, España

COMITÉ CIENTÍFICO

Abel Calle, Universidad de Valladolid, España
Fernando Camacho, Universidad de Valencia, España
Eduardo De Miguel, INTA - Instituto Nacional de Técnica Aeroespacial, España
Arnon Karnieli, Ben-Gurion University of the Negev, Israel
Agustín Lobo, Institut de Ciències de la Terra "Jaume Almera". CSIC, España
Luis Morales, Universidad de Chile, Chile
Ismael Moya, LMD-CNRS. Ecole Polytechnique, Francia
Françoise Nerry, LSIIT/TRIO. Louis Pasteur University, Francia
Albert Olioso, INRA-Avignon, Francia
Jean-Louis Roujean, Meteo-France, Francia
Alain Royer, Université de Sherbrooke, Canadá
Jiancheng Shi, University of California, EE.UU.
Wout Verhoeft, University of Twente - ITC, Países Bajos
Raúl Zurita-Milla, University of Twente - ITC, Países Bajos

Esta obra se publica bajo una licencia Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International License.

**EDITORIAL DE LA UNIVERSITAT POLITÈCNICA DE VALÈNCIA**

Depósito Legal: V-2341-2015

ISSN: 1133-0953

eISSN: 1988-8740

MAQUETACIÓN

Enrique Mateo, Triskelion diseño editorial

JUNTA DIRECTIVA AET

<http://www.aet.org.es/>

PRESIDENTE

José Antonio Sobrino Rodríguez

Unidad de Cambio Global - Laboratorio de Procesado de Imágenes. Universitat de València. Parc-Científic.
C/ Catedrático José Beltrán nº2 – 46980 Paterna (Valencia).
sobrino@uv.es

VICEPRESIDENTE

Evangelina Oriol Pibernat

Jubilada de la Agencia Espacial Europea, París (Francia).
evaoriolp@gmail.com

SECRETARIA

María José González Bonilla

Centro Espacial INTA-Torrejón (CEIT)
Instituto Nacional de Técnica Aeroespacial - INTA.
Ctra. Aljivar Km.4 - 28850 Torrejón de Ardoz (Madrid)
glezbmj@inta.es

TESORERA

Diana Sánchez Fernández

Instituto Murciano de Investigación y Desarrollo Agrario y Alimentario (IMIDA)
C/ Mayor, s/n. 30150 La Alberca. 30150 Murcia (Murcia).
tesorero@aet.org.es

VOCAL

Juan Carlos Jiménez Muñoz

Unidad de Cambio Global - Laboratorio de Procesado de Imágenes. Universitat de València. Parc-Científic.
C/ Catedrático José Beltrán nº2 – 46980 Paterna (Valencia).
jcm@uv.es

VOCAL

María González de Audicana Amenábar

Instituto de Innovación y Sostenibilidad de la Cadena Agroalimentaria (IS-FOOD), grupo TERRAE
Universidad Pública de Navarra
Campus Arrosadía s/n, 31006, Pamplona
maria.audicana@unavarra.es

VOCAL

Abel Calle Montes

Grupo de Óptica Atmosférica (GOA)
Universidad de Valladolid
Paseo de Belén 7, 47011 Valladolid
Abel@goa.uva.es

VOCAL

Luis Ángel Ruiz Fernández

Grupo de Cartografía GeoAmbiental y Teledetección (CGAT).
Universitat Politècnica de València.
Camino de Vera s/n - 46022 Valencia
laruiz@cfg.upv.es

Imagen de portada: Ejemplos de imágenes del conjunto de datos AmazonCRIME relacionadas con delitos ambientales clasificadas mediante técnicas de inteligencia artificial (Fuente: Pinto-Hidalgo y Silva-Centeno)

Sumario

- ii Consejo de Redacción y Junta Directiva de la AET
- v Editorial
- vii Información y normas para los autores

ARTÍCULOS DE INVESTIGACIÓN

- 1 AmazonCRIME: un conjunto de datos y punto de referencia de **Inteligencia Artificial Geoespacial** para la clasificación de áreas potenciales vinculadas a Crímenes Ambientales Transnacionales en la Selva Amazónica
Jairo J. Pinto-Hidalgo, Jorge A. Silva-Centeno
- 23 Estimación de emisiones atmosféricas de CO₂, NO₂, CO, NH₃ y *Black Carbon* vía *bottom up*, generados por quema de biomasa en el norte de América del Sur
Germán M. Valencia, Jesús A. Anaya, Francisco J. Caro-Lopera
- 49 Cartografía del abandono de cultivos de cítricos mediante el uso de datos altimétricos: LiDAR y fotogrametría SfM
Sergio Morell-Monzó, María-T. Sebastiá-Frasquet, Javier Estornell
- 61 Estimación de la producción de cebada a partir de imágenes Sentinel-1, Sentinel-2 y variables climáticas
Cristian Iranzo, Raquel Montorio, Alberto García-Martín

CASOS PRÁCTICOS

- 73 Tendencia anual, anomalías y predicción del comportamiento de cobertura de vegetación con imágenes Landsat y MOD13Q1, microcuenca Apacheta, Región Ayacucho
Wilmer Moncada, Bram Willems, Alex Pereda, Cristhian Aldana, Jhony Gonzales
- 87 Estimación de la subsidencia en torno a la traza de la falla de San Ramón Chile, mediante la técnica SBAS DInSAR usando imágenes TerraSAR-X
Patricio Lamperein-Polo, Paulina Vidal-Páez, Waldo Pérez-Martínez

Editorial

Estimados lectores:

En este número de la revista se presentan cuatro artículos de investigación y dos casos prácticos. El primer artículo presenta un sistema basado en redes neuronales convolucionales para la detección de delitos ambientales en la selva Amazónica a partir de una base de datos específica (AmazonCRIME) compuesta por imágenes Sentinel-2 gestionadas desde la plataforma *Google Earth Engine*. Los resultados alcanzan una fiabilidad prometedora, siendo sin duda un ejemplo de la puesta a punto de nuevas metodologías y datos de libre acceso al servicio de la protección ambiental. En el segundo artículo se describe un método para la estimación de emisiones de gases de efecto invernadero provocados por la quema de biomasa, aplicándolo a la zona norte de América del Sur entre 2001 y 2016, contribuyendo al estudio del cambio climático y sus efectos. En un tercer artículo se analiza la detección de abandonos en cultivos de cítricos, un fenómeno creciente con implicaciones medioambientales y socioeconómicas, empleando dos fuentes distintas de datos altimétricos: LiDAR PNOA y nubes de puntos obtenidas por métodos fotogramétricos a partir de imágenes desde sistemas aéreos no tripulados, evidenciando el potencial de estos datos en este tipo de estudios. En el último de los artículos de investigación se evalúa el uso combinado de

variables derivadas de imágenes de microondas y óptico (Sentinel-1 y Sentinel-2) y de variables climáticas, para la estimación de la producción en cultivos de cebada, revelándose como una estrategia adecuada para la modelización de este importante parámetro agronómico.

De los dos casos prácticos presentados, en el primero se estudian la tendencia anual, las anomalías y la predicción de la cobertura de vegetación en una microcuenca de la región de Ayacucho, en Perú, a partir de imágenes Landsat y del producto MOD13Q1. En el segundo, se muestra el empleo de la técnica DInSAR con una serie temporal de imágenes TerraSAR-X para identificar las áreas de subsidencia en la falla de San Ramón, en Santiago de Chile, obteniendo las tasas de desplazamiento y sus velocidades medias.

Deseamos que estos trabajos sean de vuestro interés, agradecemos a los revisores científicos su dedicación desinteresada y os seguimos animando a enviarnos comunicaciones originales. También os trasladamos nuestra ilusión por la celebración del XIX Congreso de la Asociación Española de Teledetección que tendrá lugar en Pamplona entre el 29 de junio y 1 de julio de 2022 ¡Esperamos vernos allí!

Un saludo cordial,

Luis Ángel Ruiz
Director - Revista de Teledetección

Información y normas para los autores

Revista de Teledetección es una publicación científico-técnica de carácter semestral en la que se publican artículos originales de investigación, relacionados con las diversas aplicaciones de la Teledetección y con su desarrollo metodológico. En secciones aparte, se presentan Casos Prácticos que describen experiencias en las que se utiliza la teledetección para desarrollar proyectos de análisis y gestión territorial o para desarrollar misiones, sensores o segmentos terrestres. Además, se incluyen recensiones críticas de libros, programas y material docente relacionado con métodos o aplicaciones de la teledetección, así como resúmenes de tesis doctorales.

Revista de Teledetección se publica ininterrumpidamente desde 1993 y constituye el órgano de expresión científica de la Asociación Española de Teledetección, siendo una publicación de referencia en el ámbito de los desarrollos y aplicaciones de esta tecnología. Los artículos originales de investigación son sometidos a un proceso de evaluación externa y anónima por pares, por parte de miembros especialistas de la comunidad científica nacional e internacional de teledetección, supervisado y coordinado por el Consejo de Redacción. *Revista de Teledetección* se compromete a comunicar a los autores la aceptación o rechazo de los manuscritos en un plazo de 3 meses.

1. Indexación

Revista de Teledetección se encuentra indexada en Scopus (<http://www.scopus.com>), Emerging Sources Citation Index, en el Catálogo LATINDEX (<https://www.latindex.unam.mx>) y DICE (<http://epuc.cchs.csic.es/dice/>), en las bases de datos ISOC e ICYT (Instituto de Estudios Documentales sobre Ciencia y Tecnología, IEDCYT-CSIC), MIAR (<http://miar.ub.edu/es>), DOAJ y SHERPA/RoMEO. A través del portal de difusión electrónica de revistas científicas DIALNET de la Universidad de La Rioja (<http://dialnet.unirioja.es>), del sitio web de la Asociación Española de Teledetección (<http://www.aet.org.es/?q=numeros>) y de la plataforma OJS de

la revista (<http://polipapers.upv.es/index.php/raet>) se puede acceder a sus contenidos en formato .pdf. *Revista de Teledetección* forma parte de e-revist@s, una Plataforma Open Access de Revistas Científicas Electrónicas españolas y latinoamericanas (<http://www.erevistas.csic.es>), y posee el Sello de Calidad FECYT desde 2014.

2. Presentación de originales

A partir de 2014, el envío de originales se realiza a través de la plataforma digital OJS (<http://polipapers.upv.es/index.php/raet>), siguiendo las instrucciones que aparecen en el margen derecho (Submissions-Author Guidelines). Es preciso registrarse como autor la primera vez, o simplemente identificarse y acceder al perfil de autor en caso de estar ya registrado.

2.1. Artículos científicos

Los artículos deberán ser obligatoriamente originales e inéditos. El trabajo no excederá de 25 páginas (DIN-A4) incluidos resúmenes, figuras, tablas y referencias. Los trabajos deberán ir precedidos de título y resúmenes en español e inglés, finalizando con las palabras clave también en español e inglés. Para facilitar la edición se recomienda escribir los artículos utilizando la plantilla Word disponible en el siguiente enlace: <http://polipapers.upv.es/index.php/raet/about/submissions#onlineSubmissions>

El Consejo de Redacción seleccionará los artículos en función de su calidad y originalidad. Para desarrollar esta tarea de supervisión, contará con la colaboración de especialistas de la comunidad científica nacional e internacional de teledetección quienes, de forma anónima, informarán sobre la conveniencia o no de la publicación de los artículos evaluados o, en su caso, sobre las modificaciones que el autor deberá incluir en el trabajo. La maquetación final del artículo se realizará desde la secretaría de la revista, una vez que se haya

recibido la versión final del mismo, aprobada por el Consejo de Redacción.

Es recomendable ajustarse a los siguientes criterios:

- **Título** en minúsculas, excepto la primera letra. Además del título en español, los autores indicarán el título del artículo en inglés.
- A continuación, **autores** e institución en la que trabajan, dirección y correo electrónico para el autor principal.
- **Resumen / Abstract** y palabras clave / keywords (mínimo de 5), en inglés y español.
- **Texto principal:** las secciones principales irán numeradas, en minúsculas y negrita tamaño 14, y las sub-secciones en minúsculas y negrita tamaño 12.
- Las líneas irán numeradas correlativamente desde el inicio hasta el final del texto.
- **Referencias. Tablas. Pies de figura y figuras**, insertadas en la parte final del documento.
- Las **citas** de autor, en el texto, irán en minúscula (Ej. Fernández, 2006 ó Fernández *et al.*, 2005).
- Las **tablas y figuras** deberán llevar un título y estar numeradas consecutivamente. Se indicará su inserción en el texto indicando: "Insertar fig. XX". Las figuras pueden insertarse al final del texto para la versión de evaluación, pero se requerirá posteriormente remitirlas en ficheros gráficos (tif, jpg), con suficiente resolución (300 ppp o superior). Se debe prestar especial atención a la rotulación, para que sean legibles al tamaño final de reproducción. Se pueden incluir figuras en color, aunque conviene considerar que sólo se reproducirán en color para la edición electrónica de la revista, siendo en blanco y negro para la versión impresa. Las tablas se enviarán en un archivo de Microsoft Excel independiente, evitando figuras.
- Se intentará evitar la inclusión de **notas a pie de página**. En caso necesario, la numeración será correlativa. Se indicarán en el texto como superíndices.

Las referencias irán al final del texto del artículo y sólo se incluirán las citadas en el texto. Estarán dispuestas por orden alfabético según el apellido del autor o autores, nombre o nombres propios con inicial, seguido de la fecha, título en cursiva, lugar de edición y editorial (Bovik, A.C. 2010. *Handbook of image and video processing*. New York: Elsevier). Los artículos de revista se redactarán como sigue: apellidos del autor o autores con las iniciales de sus nombres propios, fecha de edición, título del trabajo, nombre de la revista en cursiva, volumen en cursiva, número (entre paréntesis), primera y última página (Ej. Benz, U. C., Hofmann, P., Willhauck, G., Lingenfelder, I., Heynen, M. 2004. Multi-resolution, object-oriented fuzzy analysis of remote sensing data for GIS-ready information. *ISPRS Journal of Photogrammetry and Remote Sensing*, 58(3), 239-258).

Journal of Photogrammetry and Remote Sensing, 58(3), 239-258).

2.2. Presentación de casos prácticos

La revista incluirá una sección que describa experiencias prácticas en las que se haya utilizado la teledetección para desarrollar un proyecto de gestión o análisis territorial, desarrollo de misiones, sensores, segmentos terrestres, etc. Su objetivo es mostrar ejemplos de cómo la teledetección se emplea en situaciones prácticas. Estos artículos seguirán el proceso de revisión estándar de la revista y la misma estructura formal de los artículos, aunque las referencias bibliográficas serán más sucintas.

2.3. Críticas de libros o programas

Se incluirán recensiones críticas de libros, programas o material docente relacionados con métodos o aplicaciones de la teledetección, así como resúmenes de tesis doctorales. Se incluirán en las mismas los datos completos de la obra: ficha bibliográfica del libro, datos de referencia del programa (incluyendo versión, coste, dirección de contacto), o de la página web comentada (incluyendo último acceso), así como los del autor de la crítica.

Todos los trabajos se enviarán a través de la plataforma digital de la revista (<http://polipapers.upv.es/index.php/raet>).

3. Asociación Española de Teledetección

La Asociación Española de Teledetección (AET) se inscribió en el Registro de Asociaciones del Ministerio del Interior el 8 de Septiembre de 1988 con el número nacional 81537.

Los fines son fomentar, facilitar, aunar y difundir los trabajos de investigación interdisciplinar en todos los aspectos de la Teledetección en España mediante:

- a) Organización de reuniones, periódicas o no, para la exposición y discusión de trabajos científicos.
- b) Revista, actas, boletines y servicios de información bibliográfica.
- c) Organización de cursillos, conferencias y publicaciones para la difusión de la investigación científica en la relación de la Teledetección.
- d) Creación de Grupos temáticos de trabajo para el estudio de problemas concretos.
- e) Fomento de las enseñanzas y estímulo de la investigación en relación con las ramas de la ciencia vinculadas con Teledetección.
- f) La ejecución de cualesquiera otros fines en relación con la actividad principal, siempre que sean compatibles con las disposiciones legales y con las normas dictadas al efecto por los organismos competentes.



AmazonCRIME: un conjunto de datos y punto de referencia de Inteligencia Artificial Geoespacial para la clasificación de áreas potenciales vinculadas a Crímenes Ambientales Transnacionales en la Selva Amazónica

Jairo J. Pinto-Hidalgo *, Jorge A. Silva-Centeno

Programa de Posgraduación en Ciencias Geodésicas, Universidade Federal do Paraná, Av. Coronel Francisco Heráclito dos Santos, 210, Jardim das Américas, Curitiba, Brasil.

Resumen: En este artículo es abordado el desafío de detectar áreas vinculadas con crímenes ambientales transnacionales en la selva amazónica usando datos de Inteligencia Geoespacial, imágenes de libre acceso Sentinel-2 proporcionadas por el programa Copernicus, así como también las capacidades de procesamiento en la nube de la plataforma *Google Earth Engine*. Para esto, se generó un conjunto de datos que consta de 6 clases con un total de 30.000 imágenes multiespectrales de 13 bandas, etiquetadas y georreferenciadas que es usado para alimentar modelos avanzados de Inteligencia Artificial Geoespacial (redes neuronales convolucionales profundas) especializados en las tareas de clasificación de imágenes. Con el conjunto de datos presentado en este artículo es posible obtener una exactitud global (*overall accuracy*) de clasificación de 96,56%. Es también demostrado cómo los resultados obtenidos se pueden utilizar en aplicaciones reales para apoyar la toma de decisiones destinadas a prevenir los Crímenes Ambientales Transnacionales en la selva Amazónica. El Conjunto de datos *AmazonCRIME* se coloca a disposición del público en el repositorio: <https://github.com/jp-geoAI/AmazonCRIME.git>.

Palabras clave: Crímenes Ambientales Trasnacionales, Selva Amazónica, Sentinel-2, Inteligencia Geoespacial, Inteligencia Artificial Geoespacial.

AmazonCRIME: a Geospatial Artificial Intelligence dataset and benchmark for the classification of potential areas linked to Transnational Environmental Crimes in the Amazon Rainforest

Abstract: In this article the challenge of detecting areas linked to transnational environmental crimes in the Amazon rainforest is addressed using Geospatial Intelligence data, open access Sentinel-2 imagery provided by the Copernicus programme, as well as the cloud processing capabilities of the Google Earth Engine platform. For this, a dataset consisting of 6 classes with a total of 30,000 labelled and geo-referenced 13-band multispectral images was generated, which is used to feed advanced Geospatial Artificial Intelligence models (deep convolutional neural networks) specialised in image classification tasks. With the dataset presented in this paper it is possible to obtain a classification overall accuracy of 96.56%. It is also demonstrated how the results obtained can be used in real

To cite this article: Pinto-Hidalgo, J.J., Silva-Centeno, J.A. 2022. AmazonCRIME: a Geospatial Artificial Intelligence dataset and benchmark for the classification of potential areas linked to Transnational Environmental Crimes in the Amazon Rainforest. *Revista de Teledetección*, 59, 1-21. <https://doi.org/10.4995/raet.2022.15710>

* Corresponding author: jairopinto@ufpr.br

applications to support decision making aimed at preventing Transnational Environmental Crimes in the Amazon rainforest. The AmazonCRIME Dataset is made publicly available in the repository: <https://github.com/jp-geoAI/AmazonCRIME.git>.

Key words: Transnational Environmental Crimes, Amazon rainforest, Sentinel-2, Geospatial Intelligence, Geospatial Artificial Intelligence.

1. Introducción

Los Crímenes Ambientales Transnacionales (CATs) se han convertido en uno de los principales impulsores financieros de la delincuencia organizada, afectan directamente los recursos naturales y generan serias consecuencias y amenazas para el mantenimiento de la paz, seguridad, salud humana, economía y desarrollo sostenible de la sociedad civil y los gobiernos (International Criminal Police Organization [INTERPOL], 2018). Se refieren a cualquier actividad u omisión en contra de la ley, cruzan las fronteras, se basan en el uso ilegal de los recursos naturales, originando impactos directos sobre el medio ambiente irreversibles y de grande alcance.

El carácter transnacional, los vincula con otras actividades delictivas, como el tráfico ilícito de drogas, legitimación de capitales, crimen organizado, corrupción y trata de personas, las cuales varían entre países y regiones geográficas (White, 2011). En general, realizan transformaciones en la diversidad biológica que contribuyen con el calentamiento global (INTERPOL, 2018; Zabyelina et al., 2020; Global Initiative Against Transnational Organized Crime, 2021). En algunos casos, están fuertemente estructurados por grupos del crimen organizado, grandes corporaciones, gobiernos cómplices, funcionarios públicos corruptos y profesionales altamente especializados (Gore et al., 2019), utilizan técnicas sofisticadas, tecnologías modernas y redes de conexión similares al tráfico ilícito de drogas (United Nations Environment Programme [UNEP], 2012), por ejemplo, el empleo de pistas de aterrizaje clandestinas que les permiten operar y conectarse entre países y continentes.

Como consecuencia, el alto nivel de organización de estos grupos criminales afecta sustancialmente las políticas públicas destinadas a resguardar

los activos ambientales, exigiendo el empleo y dedicación de muchos recursos humanos, financieros y económicos (European Union Agency for Law Enforcement Cooperation [EUROPOL], 2011). En este sentido, a medida que estos crímenes persisten, crecen y destruyen importantes ecosistemas terrestres, como la Amazonía y regiones fronterizas, los impactos ambientales son directos y visibles principalmente en áreas legalmente protegidas, convirtiéndolas en corredores aéreos, fluviales y terrestres para nuevas rutas y actividades vinculadas con el crimen organizado trasnacional.

Por ejemplo, la región amazónica que se extiende a lo largo de varios países (Bolivia, Brasil, Colombia, Ecuador, Guayana, Guayana Francesa, Perú, Surinam y Venezuela) tiene un área aproximada de 8.470.209 km² equivalente al 40% del territorio de América del Sur (Red Amazónica de Información Socioambiental Georreferenciada [RAISG], 2020a), genera entre el 16% y 20% del agua dulce y el 10% de la biodiversidad mundial, produce más del 10% de oxígeno del planeta y es considerada la mayor selva tropical del mundo (Banco de Desarrollo de America Latina [CAF], 2019). Sin embargo, a pesar de ser una importante región estratégica debido a la abundancia de los recursos hídricos, energéticos y minerales que posee, es uno de los escenarios donde se verifican complejos CATs (Zabyelina et al., 2020; Lycia et al., 2019).

En los últimos 10 años la minería ilegal, el tráfico ilícito de drogas, la producción de cultivos ilícitos de coca (United Nations Office on Drugs and Crime [UNODC], 2012) y la construcción de pistas de aterrizaje clandestinas (Insight Crime, 2020; Exército Brasileiro, 2018) se han intensificado (Lycia et al., 2019). Los cultivos ilícitos de coca, por ejemplo, a menudo están conectados y se superponen con áreas productoras de oro,

convirtiéndose en una estrategia por parte del crimen organizado, para diversificar sus fuentes de ingreso y al mismo tiempo permanecer activos en el tráfico ilícito de drogas (Zabyelina et al., 2020). Colombia, Perú y Bolivia han sido declarados por la UNODC, como las principales fuentes de producción de cultivos de coca y abastecimiento mundial de cocaína (UNODC, 2021a). Venezuela ha sido denunciada por tener participación y complicidad con el tráfico ilícito de drogas, minería ilegal y crímenes contra la humanidad (United Nations Human Rights Council [UNHRC], 2020; Insight Crime, 2020). Brasil registró un aumento de la deforestación del 34% en el año 2020 (Instituto Nacional de Pesquisas Espaciais [INPE], 2020) y varias investigaciones han identificado y confirmado la existencia de más de 2300 puntos y 245 áreas relacionadas con la minería ilegal de oro, diamantes y coltán, distribuidas por toda la región amazónica (RAISG, 2018a).

Por consiguiente, la presencia de grupos del crimen organizado en la selva amazónica ha convertido a la región suramericana en el epicentro mundial del comercio transnacional ilegal de recursos naturales y del tráfico ilícito de drogas (Global Initiative Against Transnational Organized Crime, 2016; UNODC, 2019c), generando como consecuencia una degradación ambiental acelerada que ha permitido abrir espacio a diferentes formas de violencia.

Organizaciones como la UNODC, la INTERPOL, la RAISG y el Centro de Gestión y Operación del Sistema de Protección de la Amazonía (CENSIPAM), han implementado el uso de técnicas de teledetección y extensas evaluaciones de campo, entre otras tecnologías geoespaciales, para el monitoreo y detección de delitos ambientales en la selva amazónica y regiones fronterizas; además de importantes contribuciones para la implementación de políticas públicas contra estos devastadores crímenes. Sin embargo, las metodologías aplicadas para la identificación y detección de las áreas afectadas se basan en expertos humanos, haciendo que las tareas de análisis e interpretación de las imágenes de satélite sean lentas y costosas.

Debido a su extensión, actuar en escenarios como la amazonía demanda métodos que permitan automatizar la detección de delitos ambientales a gran escala, para facilitar la planificación de operaciones de interdicción terrestre destinadas

a resguardar los activos ambientales de la región, además de proteger los recursos naturales a través de la formulación de normas legales nacionales e internacionales. En este contexto, la Inteligencia Geoespacial (*Geospatial Intelligence - GEOINT*) y la Inteligencia Artificial Geoespacial (*Geospatial Artificial Intelligence - GeoAI*), se convierten en importantes herramientas que permiten el análisis de datos geoespaciales para describir, evaluar y representar visualmente características y actividades georreferenciadas en la Tierra.

La GEOINT, se caracteriza por su capacidad de identificar, recopilar, almacenar y manipular datos para crear conocimiento geoespacial a través del pensamiento crítico, el razonamiento geoespacial y las técnicas analíticas; los datos pueden ser estructurados (información sobre ubicaciones y formas de características geográficas, como coordenadas geográficas, imágenes de satélite) y datos no estructurados (información geográfica que no está organizada de una manera predefinida, como texto con información geográfica de alguna actividad). Describe e interpreta el impacto humano de un determinado evento, permitiendo presentar éticamente el conocimiento para la toma de decisiones (Pennsylvania State University, 2020). Se diferencia de otras fuentes de recopilación de inteligencia, porque inherentemente integra y se enriquece de múltiples fuentes de inteligencia (*multiINT*) en un contexto espacio temporal (Clark, 2020).

En la actualidad la GOINT, combina diferentes herramientas y tecnologías como la inteligencia artificial (*Artificial Intelligence - AI*), el aprendizaje automático (*Machine Learning - ML*), el *Big Data*, la experiencia humana para la recopilación de información y el procesamiento de datos procedentes de múltiples fuentes, destacándose el uso de fuentes abiertas (United States Geospatial Intelligence Foundation [USGIF], 2020; Clark, 2020; Coorey, 2018), las cuales no exigen ninguna restricción a su acceso y pueden ser obtenidas principalmente a través de internet (medios de comunicación digital, libros, artículos científicos, información geoespacial de libre acceso, entre otros) (Lowenthal, 2020), permitiendo adoptar nuevos enfoques para desarrollar una mayor conciencia situacional en la toma de decisiones.

En este sentido, su uso permite descubrir vínculos y patrones relevantes en los datos, para

proporcionar información y obtener ventajas en la toma de decisiones complejas (Letitia, 2013), por ejemplo, las destinadas a combatir el crimen organizado transnacional y los delitos ambientales.

La GeoAI es una subdisciplina de la inteligencia artificial que utiliza el aprendizaje automático, la ciencia de la información geográfica, la minería de datos y computación de alto rendimiento, para extraer y analizar información de grandes conjuntos de datos geoespaciales (United Nations Committee of Experts on Global Geospatial Information Management [UN-GGIM], 2020; VoPham et al., 2018). En este particular, el aprendizaje automático y en especial las redes neuronales profundas (*Deep Neural Networks – DNN*) han contribuido para resolver una gran variedad de problemas debido a su capacidad de aprender características representativas y discriminatorias a partir de los datos (Lecun et al., 2015).

Recientemente, en el marco de los programas de observación de la Tierra Copernicus de la Unión Europea y el Proyecto Landsat del Servicio Geológico de los Estados Unidos (USGS) y la Administración Nacional de Aeronáutica y del Espacio (NASA), varios satélites ópticos y de radar de apertura sintética se lanzaron con la finalidad de ofrecer a la comunidad científica grandes cantidades de datos de teledetección de libre acceso (Kussul et al., 2017). Esto ha promovido enfoques interdisciplinarios para estudiar la Tierra que han abierto oportunidades sin precedentes para una amplia gama de aplicaciones y crearon la base para el uso de métodos de ML (Vargas, 2020; Zhang et al., 2016) en muchas de las tareas de la comunidad de teledetección. Algunos enfoques se han dirigido a la clasificación de escenas, la detección y segmentación de objetos en imágenes de satélite (Janowicz et al., 2020), la fusión y el registro de imágenes (Ma et al., 2019), entre otros, con resultados favorables que han superado en algunos aspectos las capacidades de un operador humano.

Con el fin de fomentar el desarrollo de aplicaciones GeoAI para la clasificación de imágenes, destinadas a prevenir el impacto ambiental que producen las actividades del crimen organizado en la selva amazónica, es esencial disponer de grandes cantidades de datos correctamente etiquetados. Sin embargo, reunir esta gran cantidad de imágenes de satélite y recopilar información

asociada con las características reales del terreno (verdad de campo) para relacionar los datos de la imagen y entrenar modelos de DNN, es una tarea no trivial que requiere considerables esfuerzos de ingeniería y tiempo.

Actualmente, la Agencia Espacial Europea (ESA) a través del programa Copernicus, proporciona datos de observación de la Tierra de alta calidad, que se encuentran disponibles libremente con la intención de impulsar aplicaciones destinadas a mejorar la gestión ambiental, comprender y mitigar los efectos del cambio climático y garantizar la seguridad ciudadana (European Commission, 2015).

Considerando esta disponibilidad de grandes cantidades de datos de teledetección fiables y continuos, en este artículo se presenta una opción viable para la detección de CATs usando inteligencia artificial y métodos de inteligencia geoespacial para analizar imágenes de satélite y un banco de datos georreferenciados. El artículo ofrece tres principales contribuciones: 1) describe la metodología para la creación del conjunto de datos *AmazonCRIME*, compuesto por 30.000 imágenes multiespectrales de 13 bandas georreferenciadas, provenientes del satélite Sentinel-2, etiquetadas con 6 clases diferentes, destinadas a la identificación y clasificación de áreas vinculadas con CATs en la selva amazónica; 2) coloca a disposición de la comunidad científica el conjunto de datos propuesto; 3) demuestra a través de aplicaciones reales, el uso efectivo de *AmazonCRIME*, mediante el entrenamiento de modelos GeoAI cuyas predicciones identifican y clasifican CATs, en áreas naturales protegidas localizadas en la región amazónica.

2. Trabajos relacionados

El primer componente para un proyecto GeoAI está en la calidad, cantidad y obtención del conjunto de datos que se utilizará para el entrenamiento de los modelos DNN. Sin embargo, debido a las características propias de los datos de teledetección, existen desafíos en torno a la disponibilidad y la proporción de conjuntos de datos de entrenamiento etiquetados para extraer conocimientos de las imágenes de satélite (UN-GGIM, 2020), ya que generar estos conjuntos de datos es una tarea difícil y compleja (Hoeser et al., 2020). Para

superar estos obstáculos diversos investigadores han realizado estudios relacionados con la generación de conjuntos de datos de imágenes satelitales y fotografías aéreas, con la finalidad de contribuir con el desarrollo de aplicaciones específicas de GeoAI (Schmitt et al., 2021; Camps-Valls et al., 2021).

En este sentido en la Tabla 1, es presentada una breve descripción de trabajos relacionados con este dominio, donde es posible observar que,

para la detección de objetos y aplicaciones de segmentación semántica, los conjuntos de datos se componen principalmente de fotografías aéreas en color o imágenes de satélite de muy alta resolución espacial (alrededor de 50 cm). Al contrario, cuando se dispone de imágenes de menor resolución espacial, los conjuntos de datos se utilizan para tareas de clasificación, ya que la delimitación de objetos pequeños se hace difícil.

Tabla 1. Conjunto de datos para aplicaciones de GeoAI con imágenes de teledetección.

Conjunto de datos	Fuente	Tamaño de la imagen	Nº de imágenes	Tarea / Visión Computacional	Visión General / Aplicaciones	Referencia
DOTA	Fotografía aérea en color	800×800 a 4000×4000	2.806	Detección de objetos	15 clases 188.000 instancias	(Xia, et al., 2018)
Agriculture-Vision	Fotografía aérea en color	512×512	21.061	Segmentación de instancias	6 tipos de anotaciones	(Chiu, et al., 2020)
LandCover.ai	Fotografía aérea en color	9000×9000	41 ortofotos	Segmentación semántica	3 clases de cobertura del suelo	(Boguszews, et al., 2020)
UC Merced Land Use Dataset	Fotografía aérea en color	256×256	2.100	Clasificación	21 clases de cobertura del suelo	(Yang y Newsam, 2010)
SAT-4	Fotografía aérea en color	28×28	500.000	Clasificación	4 clases de cobertura del suelo	(Basu, et al., 2015)
SAT-6	Fotografía aérea en color	28×28	405.000	Clasificación	6 clases de cobertura del suelo	(Basu, et al., 2015)
Cactus Aerial Photos	Fotografía aérea en color	32×32	17.000	Clasificación	2 clases	(López, et al., 2019)
RESISC45	Fotografía aérea en color	256×256	31.500	Clasificación	45 clases	(Cheng y Lu, 2017)
DeepGlobe – Building Detection	WorldView-3 (0,3 m)	650×650	24.586	Segmentación semántica	1 clases	(Demir, et al., 2018)
Brazilian Cerrado-Savanna	RapidEye (0,3 m)	64×64	1.311	Clasificación	4 clases	(Nogueira, et al., 2016)
Brazilian Coffee Scenes Dataset	SPOT	64×64	51.004	Clasificación	2 clases	(Penatti y Dos Santos, 2015)
Planet	Planet's Flock 2 (0,9 m)	256×256	150.000	Clasificación	13 categorías de cobertura del suelo / selva amazónica	(Planet Labs, 2017)
So2Sat LCZ42	Sentinel-1 Sentinel -2 (10 m)	32×32	400.000	Clasificación	17 clases	(Zhu, et al., 2020)
EuroSAT	Sentinel-2 (10 m)	64×64	27.000	Clasificación	10 clases de cobertura del suelo	(Helber y Borth, 2019)
BigEarthNet	Sentinel-2 (10 m)	120×120 60×60 20×20	590.326	Clasificación	43 clases de cobertura del suelo	(Sumbul y Markl, 2019)
OpenSARUrban	Sentinel -1 (10 m)	100×100	33.358	Clasificación	10 clases de interpretación urbana	(Zhao, et al., 2020)
SEN12MS	Sentinel-1, Sentinel-2 (10 m), MODIS Land Cover (250 m)	256×256	541.986	Clasificación	Cobertura del suelo (Schmitt, et al., 2019) MODIS pueden utilizarse como etiquetas o datos auxiliares	

Se observa que hay una gran variedad de conjuntos de datos especiales disponibles públicamente para fomentar la investigación relacionada con la GeoAI, se centran en aplicaciones agrícolas, el uso y la cobertura del suelo y la detección de características naturales y culturales comunes. Los datos de Sentinel se utilizan con frecuencia para componer este tipo de conjunto de datos, debido a que son gratuitos (de fácil acceso) y ofrecen una resolución espacial relativamente buena. Otro factor por considerar es la extensión del área de estudio. En el caso de grandes extensiones, el uso de imágenes de satélite ofrece ventajas con respecto a las fotografías aéreas.

3. Teledetección y Datos de Inteligencia Geoespacial

Se utilizaron datos disponibles libremente provenientes de fuentes *multi-INT* como OSINT (*Open-Source Intelligence*) y GEOINT (*Geospatial Intelligence*), para generar el conjunto de datos y obtener la verdad de campo. Inicialmente se hizo uso de la plataforma de *Google Earth Engine* (GEE) para descargar y procesar las imágenes multiespectrales Sentinel-2. Posteriormente para obtener la verdad de campo, se emplearon datos derivados de la RAISG, informes de monitoreo de territorios afectados por cultivos ilícitos de la UNODC, Agencia Nacional de Aviación Civil (ANAC), *openAIP*, MapBiomas Brasil y la Base de Datos Mundial sobre Áreas Protegidas (WDPA).

3.1. Sentinel-2

La misión Copernicus Sentinel-2 (European Space Agency [ESA], 2015) está conformada por una constelación de dos satélites en órbita polar heliosincrónica en fase de 180° entre sí. Su objetivo es monitorear la variabilidad de la superficie de la Tierra, captura imágenes en 13 bandas multiespectrales con resoluciones espaciales de 10 m, 20 m y 60 m. Posee un ancho de franja de hasta 290 km y una resolución temporal de 10 días en el Ecuador con un satélite y 5 días con dos satélites respectivamente; características que, en condiciones libre de nubes, permiten apoyar el monitoreo de la cobertura terrestre en tiempos oportunos. Los productos Sentinel-2 disponibles para los usuarios poseen niveles de procesamiento 1C y 2A. Para

el conjunto de datos *AmazonCRIME*, cada imagen está conformada por 13 bandas multiespectrales georreferenciadas, nivel 1C, con una cobertura de nubes máxima de 5%. Se generaron compuestos de imágenes con combinaciones de banda RGB (4,3,2) y color infrarrojo CIR (8, 4, 3). No se efectuó ningún procesamiento adicional.

3.2. Red Amazónica de Información Socioambiental Georreferenciada

La RAISG (RAISG, 2012) es un consorcio de organizaciones de la sociedad civil, conformado por seis países amazónicos (Bolivia, Brasil, Colombia, Ecuador, Perú y Venezuela), que, con apoyo de la cooperación internacional, tiene como principal objetivo generar y difundir mediante protocolos comunes, informes, datos estadísticos, sociales, ambientales y geoespaciales de la selva amazónica. Para obtener información de las áreas afectadas por la minería ilegal y deforestación, se descargaron datos del mapa de minería ilegal en Territorios Indígenas y Áreas Naturales Protegidas en la Amazonía (RAISG, 2018b) y de la sección de descargas de la página oficial (RAISG, 2020b).

3.3. Informes de Monitoreo de Territorios Afectados por Cultivos Ilícitos

El Programa de Monitoreo de Cultivos Ilícitos (ICMP) de la UNODC, actualmente promueve el desarrollo de un proyecto global que, a través de elementos técnicos y estratégicos centrados en evidencias técnicas y objetivas, apoya la realización de estudios de monitoreo sobre la coca en Bolivia, Colombia y Perú; sobre la amapola en Afganistán, México, Myanmar y un estudio sobre el cannabis en Nigeria (UNODC, 2021b; UNODC, 2021c). Proporciona apoyo técnico y supervisión directa en los diferentes sistemas nacionales de monitoreo con la finalidad de garantizar los estándares internacionales metodológicos de los datos que son producidos. Anualmente generan una serie de informes que, mediante el uso de técnicas de teledetección, sistemas de información geográfica (SIG) y extensas evaluaciones de campo, contemplan los resultados relacionados con la ubicación, extensión y evolución de las áreas que son afectadas por cultivos ilícitos. La verdad de campo de las áreas potenciales de cultivos ilícitos de coca para

el conjunto de datos *AmazonCRIME*, fue obtenida de los informes de monitoreo de territorio afectados por cultivos ilícitos de Bolivia (UNODC, 2017a; UNODC, 2019a), Colombia (UNODC, 2017b; UNODC, 2019b) y Perú (UNODC, 2017c; UNODC, 2018).

3.4. Agencia Nacional de Aviación Civil y OpenAIP

La ANAC (República Federativa do Brasil, 2005), es una institución federal encargada de regular y fiscalizar todas las actividades de aviación civil e infraestructura aeronáutica y aeroportuaria de Brasil. Entre sus variadas competencias, se destaca el registro y fiscalización de los aeródromos en el territorio nacional, así como también hacer disponibles datos que permitan promover investigaciones científicas y el desarrollo tecnológico. *OpenAIP* (*Open Aeronautical Information Publication*) (openAIP, 2021), por su parte, es una plataforma web, que ofrece información y datos aeronáuticos gratuitos y actualizados, entre los cuales se pueden obtener las coordenadas geográficas de los aeródromos que existen mundialmente. Los datos provenientes de estas fuentes de información permitieron obtener la ubicación de los aeródromos localizados en la selva amazónica.

3.5. MapBiomas Brasil

El proyecto MapBiomas (Souza et al., 2020), es una red de especialistas multidisciplinaria que, mediante el empleo de técnicas de teledetección, SIG, ciencias de la computación y procesamiento en la nube, genera series históricas anuales de mapas de uso y cobertura de la tierra de los diferentes biomas de Brasil, entre ellos el Amazonas, el cual es considerado uno de los biomas que tiene mayor presión sobre la cobertura terrestre original. Los datos geoespaciales generados por el proyecto MapBiomas, se utilizaron para identificar las áreas deforestadas, cuerpos de agua y bosques.

3.6. Base de Datos Mundial sobre Áreas Protegidas

La WDPA (Bingham et al., 2019), es un proyecto conjunto entre el Programa de las Naciones Unidas para el Medio Ambiente (PNUMA) y la Unión Internacional para la Conservación de la

Naturaleza (UICN), administrado por el Centro de Monitoreo de la Conservación Mundial del PNUMA (UNEP-WCMC), que, a través de su plataforma en línea, permite acceder y descargar libremente una gran variedad de información actualizada, relacionada con los datos mundiales sobre áreas protegidas terrestres y marinas. La selección de las áreas de bosque y cuerpos de agua del conjunto de datos *AmazonCRIME*, así como también la identificación de áreas protegidas para exemplificar aplicaciones de uso real, se realizó con datos geoespaciales derivados de la WDPA.

4. Creación del conjunto de datos *AmazonCRIME*

Generar y etiquetar un conjunto de datos para clasificación de imágenes en combinación con métodos de GeoAI, requiere adquirir una gran cantidad de imágenes satelitales. Con el fin de garantizar la correcta identificación de la verdad de campo y automatizar el procesamiento, selección y descarga de las imágenes, se utilizó el software QGIS (QGIS Development Team, 2021), la plataforma de GEE (Gorelick et al., 2017), y la librería de código abierto para el procesamiento de datos geoespaciales GDAL (Warmerdam, 2008). A continuación, se describen cada una de las etapas.

4.1. Verdad de Campo

El conjunto de datos *AmazonCRIME*, está conformado por seis clases: Pistas de Aterrizaje (*Airstrips*), Deforestación (*Deforestation*), Bosque (*Forest*), Minería Ilegal (*Illegal Mining*), Cultivos Ilícitos - Área Potencial de Cultivos de Coca (*Illicit Crops -Potential Coca Cultivation Area-PCCA*) y Agua (*Water*). Para seleccionar las muestras, se generaron datos geoespaciales (vectores) derivados de las diferentes fuentes de información y se visualizaron en conjunto con diferentes mosaicos de imágenes Sentinel-2 de la selva amazónica, construidos a través del complemento de GEE en QGIS. Los detalles individuales se describen en la Tabla 2.

4.2. Preparación de los datos en GEE

En esta etapa se realizó una adaptación de la metodología aplicada por (Schmitt et al., 2018), para seleccionar y procesar cada una de las

Tabla 2. Descripción de las clases que componen la verdad de campo de *AmazonCRIME*, fuente de datos y método de adquisición. El archivo vectorial de la Selva Amazónica de la RAISG se utilizó para delimitar el área de estudio.

Clase	Fuente de datos	Método de adquisición
Pistas de Aterrizaje (Airstrips)	-ANAC -openAIP	<ul style="list-style-type: none"> -Identificación de 5.812 aeródromos de todo tipo (asfaltado, no asfaltado, grama, tierra, aeropuertos, entre otros), en los 9 países amazónicos. -Inspección visual para confirmar la ubicación y selección de los aeródromos ubicados en el área de estudio con características rurales. -Selección final de 2.481 aeródromos rurales. -Detección y selección de 187 nuevos aeródromos con características rudimentarias y aislados de centros poblados. -Selección final de 2.668 aeródromos.
Deforestación (Deforestation)	-RAISG -MapBiomas	-Identificación y selección de 5.500 puntos representativos de esta clase.
Bosque (Forest)	-MapBiomas -WDPA	-Identificación y selección de 5.500 puntos representativos de esta clase.
Minería Ilegal (Illegal Mining)	-RAISG	-Identificación y selección de 7.304 puntos representativos de esta clase.
Cultivos Ilícitos (Illicit Crops – PCCA)	-UNODC Bolivia -UNODC Colombia -UNODC Perú	<ul style="list-style-type: none"> -Georreferenciación de los mapas de densidad de cultivos de coca generados en los informes de monitoreo de territorios afectados por cultivos ilícitos de: Bolivia censos del año 2016 y 2018. Identificación y selección de 712 puntos. -Colombia censos del año 2016 y 2018. Identificación y selección de 3.291 puntos. -Perú censos del año 2016 y 2017. Identificación y selección de 1.709 puntos. -Selección final de 5.712 puntos representativos de esta clase. -Los criterios considerados para la selección de las muestras se explican con mayor detalle en la preparación de los datos con GEE.
Agua (Water)	-MapBiomas -WDPA	-Identificación y selección de 5.500 puntos representativos de esta clase.

imágenes que estructuran el conjunto de datos. GEE almacena una gran cantidad de imágenes satelitales a escala global, que incluyen los datos generados por la misión Copernicus Sentinel-2. Proporciona herramientas y aplicaciones de programación que permiten procesar y analizar grandes conjuntos de datos geoespaciales (Gorelick et al., 2017). Actualmente ofrece productos de Sentinel-2 con niveles de procesamiento 1C y 2A (GEE, 2021). Los productos de nivel 1C, se encuentran ortorectificados en el sistema de referencia de coordenadas de datum WGS84, proyección UTM, con niveles digitales correspondientes a valores de reflectancia aparente por encima de la atmósfera (*Top-Of-Atmosphere reflectances – TOA*). Los productos de nivel 2A, son una evolución del nivel 1C en el que se aplican correcciones atmosféricas para proporcionar ortoimágenes con niveles digitales expresados en valores de reflectancia reales a nivel de superficie (*Bottom-Of-Atmosphere reflectances – BOA*). (ESA, 2015). En este sentido, esta plataforma se usó para obtener y exportar, recortes de imágenes de 256×256 píxeles, nivel

1C, en formato GeoTIFF, para cada clase. Se consideró la cobertura de nubes y la temporalidad de adquisición, como criterio para generar mosaicos de imágenes diferentes del área de estudio (región amazónica).

En este particular, es importante mencionar que GEE considera el criterio de cobertura de nubes en base a toda el área de interés (mosaico) y no por imagen individual, motivo por el cual no se utilizó un criterio de nubes generalizado para todos los rangos temporales. Este fue uno de los desafíos encontrados para generar mosaicos de imágenes con la menor cobertura de nubes posible, ya que, por las características climáticas propias de la región amazónica (altas temperaturas y frecuentes lluvias), resulta muy difícil generar mosaicos totalmente libres de nubes porque la región se mantiene nublada prácticamente durante todo el año.

En la Figura 1 se especifica el flujo de trabajo. A continuación, se describe en detalle cada una de las etapas:



Figura 1. Flujo de trabajo del método semiautomático para seleccionar y exportar los recortes de imágenes mediante GEE.

4.2.1. Pista de Aterrizaje

Fueron identificados y seleccionados 2.668 aeródromos, se generaron cuatro colecciones de imágenes con los siguientes criterios: para los años 2017 y 2018, con una cobertura de nubes del 1% y para los años 2016 y 2019, con una cobertura de nubes del 5%. Fueron exportados 2.668 recortes de imágenes por cada año, para un total de 10.672.

4.2.2. Minería Ilegal

Se generaron dos colecciones de imágenes, para el año 2017 con una cobertura de nubes del 5% y para el año 2019 con una cobertura de nubes del 1%. A partir de los vectores de la verdad de campo, se exportaron 3.804 muestras para el año 2017 y 3.500 muestras para el año 2019, obteniendo un total de 7.304 recortes de imágenes para esta clase.

4.2.3. Cultivos Ilícitos

Las plantaciones de cultivos de coca se caracterizan porque en un año presentan diferentes fenologías y se pueden obtener entre 4 y 5 cosechas (UNODC, 2019b), esta particularidad permite observar distintos comportamientos espectrales durante este periodo (baja/alta densidad foliar y baja/alta reflectancia del suelo) además de diferentes patrones y formas de los lotes de terreno que son empleados para este tipo de cultivo. A partir de estas variables, las siguientes etapas se realizaron para la identificación y selección de las muestras:

- Georreferenciación de los mapas de densidad de cultivos de coca publicados en los informes de monitoreo de territorio afectados por cultivos ilícitos de la UNODC.

- Selección de las muestras únicamente en las áreas de mayor densidad y territorios afectados permanentemente durante los últimos 10 años.
- Interpretación del comportamiento espectral en combinaciones RGB y CIR, tono, forma, textura, patrón y entorno geográfico. Estos elementos permitieron resaltar los objetos de interés (lotes de coca), discriminándolos de otras coberturas.
- Experiencia de campo considerando los criterios de la Primera Ley de la Geografía¹. Las áreas de cultivos ilícitos de coca se caracterizan por la presencia de lotes de terrenos (unidades espaciales) dedicados a este tipo de cultivo. Estos lotes son continuos geográficamente, se encuentran cercanos y tienden a ser más parecidos que los distantes. Poseen linderos identificables en el terreno, se encuentran plantados con el mismo tipo de especie (coca) y generalmente agrupan cultivos de la misma edad.
- Para los años correspondientes a los informes de monitoreo de cultivos ilícitos de la UNODC que fueron seleccionados, se generó una colección de imágenes por cada estación (verano, invierno, otoño, primavera), con una cobertura de nubes del 5% respectivamente. Para Bolivia y Colombia años 2016 y 2018, para Perú años 2016 y 2017.
- Muestras seleccionadas. Bolivia: 712, Colombia: 3.291, Perú: 1.709. Total: 5.712 muestras para esta clase.

¹ “Todos los lugares están relacionados entre sí, pero los lugares más próximos en el espacio tienen una relación mayor que los distantes” (Tobler, 1970).

4.2.4. Deforestación, Bosque y Agua

Se generaron dos colecciones de imágenes, para el año 2016 con una cobertura de nubes del 5% y para el año 2018 con una cobertura de nubes del 1%. A partir de los vectores de la verdad de campo, se exportaron 2.250 muestras para cada clase por año, obteniendo un total de 5.500 recortes de imágenes correspondientes por clase.

4.3. Exportación de las imágenes

Las imágenes seleccionadas por cada clase se exportaron para almacenamiento local en formato GeoTIFF, WGS-84 lat/long, nivel 1C, con una resolución espacial de 10 m, tamaño de 256×256 píxeles y 13 bandas multiespectrales respectivamente.

4.4. Inspección Visual

Posteriormente se generaron composiciones de imágenes RGB en formato JPG, para cada conjunto de imágenes/clase. En esta etapa se realizó una inspección visual con la finalidad de realizar la selección final de las mejores 5.000 muestras representativas por cada clase.

4.5. Estructura Final

Finalmente, se realizó la selección final de las muestras, las cuales permitieron generar el

conjunto de datos con imágenes de satélite denominado *AmazonCRIME*, conformado por los siguientes elementos: *AmazonCRIME_MS*, compuesto por 5.000 recortes de imágenes por cada clase, para un total de 30.000 recortes de imágenes seleccionados de 13 bandas multiespectrales – georreferenciadas en formato GeoTIFF, nivel 1C; el archivo *AmazonCRIME.csv*, con los metadatos del conjunto de datos (enumeración y etiqueta) y una versión derivada denominada *AmazonCRIME_RGB*, compuesto por las bandas 4,3,2 en formato JPG. El conjunto de datos *AmazonCRIME* en sus diferentes versiones, está disponible para el público en el repositorio: <https://github.com/jp-geoAI/AmazonCRIME.git>. Este documento debe citarse cuando el conjunto de datos sea utilizado con fines de investigación. En la Figura 2 se ilustra una visión general y algunos ejemplos.

5. Aplicaciones del conjunto de datos *AmazonCRIME*

Las redes neuronales convolucionales (*Convolutional Neural Networks - CNNs*) han demostrado su capacidad para resolver problemas de clasificación de imágenes utilizando modelos jerárquicos, millones de parámetros y grandes conjuntos de datos. En este contexto, se van a llevar a cabo dos experimentos: 1) verificar que



Figura 2. Algunas muestras de recortes de imágenes RGB por cada clase y descripción general del conjunto de datos propuesto, *AmazonCRIME*: 1) clase Pista de Aterrizaje; 2) clase Deforestación; 3) clase Bosque; 4) clase Minería Ilegal; 5) clase Cultivos Ilícitos; 6) clase Agua.

el conjunto de datos es útil para la clasificación con un modelo CNNs entrenado desde cero; 2) aplicar al caso real de identificación de CATs en áreas naturales protegidas localizadas en la región amazónica. La arquitectura *DenseNet-201* (Huang et al., 2017), se seleccionó para el entrenamiento de los modelos, debido a sus capacidades para mejorar la precisión en tareas de clasificación de imágenes. Varios trabajos (Abdani et al., 2019; Koh et al., 2021; Khan et al., 2021) han demostrado que las CNNs pueden ser esencialmente más profundas, más precisas y eficientes de entrenar si contienen conexiones más cortas entre las capas cercanas a la entrada y las cercanas a la salida, este es el principio de la arquitectura *DenseNet-201*, conectar cada capa con todas las demás en forma de retroalimentación. Entre sus principales ventajas están el hecho de que este tipo de red reduce el problema de la desaparición de los gradientes, fortalece la propagación de características, promueve la reutilización de funciones y reduce considerablemente el número de parámetros de entrenamiento (Huang et al., 2017).

Se entrenaron dos modelos con la arquitectura *DenseNet-201*, un primer modelo con las combinaciones de banda RGB y un segundo modelo con las combinaciones de banda CIR. El entrenamiento de los modelos se realizó utilizando una unidad gráfica de procesamiento (*Graphics Processing Unit – GPU*) NVIDIA Tesla T4, mediante el empleo del lenguaje de programación Python versión 3.7 y la biblioteca de código abierto TensorFlow 2.

Para evaluar el modelo, se calculó la matriz de confusión (*Confusion Matrix*). Este cálculo permite evaluar el rendimiento de un modelo

de clasificación al contabilizar y visualizar los valores de las predicciones en comparación con los valores observados (reales), mostrando cuándo una clase es confundida con otra. A partir de esta matriz pueden ser calculadas métricas que describen la calidad del producto (clasificación) como: 1) Exactitud Global (*Overall Accuracy*); 2) Precisión (*Precision*) y 3) Exhaustividad (*Recall*). La exactitud global permite medir el porcentaje de casos en que el modelo ha acertado en la clasificación, en relación con el total de los datos. La precisión, proporciona un valor de calidad relativo al número total de predicciones realizadas y la exhaustividad, proporciona un valor de calidad relativo al número total de muestra positivas. Para el entrenamiento de los modelos el conjunto de datos *AmazonCRIME* se dividió en tres subconjuntos: 1) 80% para datos de entrenamiento; 2) 10% para datos de validación; 3) 10% para datos de prueba. Los datos de entrenamiento son usados para entrenar el modelo. Los datos de validación son usados para ofrecer una evaluación del modelo que permite ajustar los hiperparámetros durante el entrenamiento. Los datos de prueba son usados para obtener una evaluación imparcial del modelo al final del entrenamiento, deben mantenerse separados del proceso de entrenamiento y son empleados apenas una vez para evaluar el rendimiento del modelo.

En la Tabla 3, se especifican las configuraciones del entrenamiento y los resultados obtenidos de las métricas de evaluación empleadas. En la Figura 3, se muestran las matrices de confusión de cada modelo.

Comparando los valores de las métricas de calidad de la clasificación, se puede apreciar que el

Tabla 3. Configuraciones del entrenamiento y resultados de las métricas de evaluación de los modelos entrenados con la arquitectura *DenseNet-201*, utilizando el conjunto de datos propuesto *AmazonCRIME*, con las combinaciones de banda RGB y CIR.

	DenseNet-201	
	Primer Modelo RGB	Segundo Modelo CIR
Conjunto de Datos (<i>Dataset</i>)		AmazonCRIME
División (<i>Splitting</i>)	entrenamiento: 80%	validación: 10%
Forma de Entrada (<i>Input shape</i>)	256×256×3	
Optimizador (<i>Optimizer</i>)	<i>Adam</i>	
Perdida (<i>Loss</i>)	<i>Categorical Cross-Entropy</i>	
Tamaño del Lote (<i>Batch size</i>)	64	
Exactitud Global (<i>Overall Accuracy</i>)	95,76%	96,56%
Precisión (<i>Precision</i>)	95,89%	96,66%
Exhaustividad (<i>Recall</i>)	95,73%	96,56%

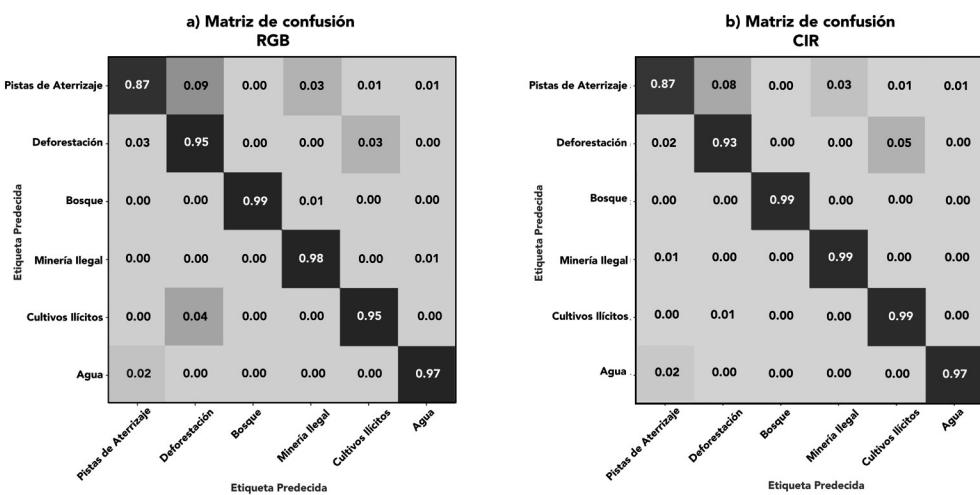


Figura 3. Matriz de confusión de los modelos entrenados con la arquitectura *DenseNet-201*, utilizando el conjunto de datos propuesto *AmazonCRIME*: a) matriz de confusión con los conjuntos de datos en combinaciones de banda RGB; b) matriz de confusión con los conjuntos de datos en combinaciones de banda CIR.

segundo modelo presentó un rendimiento superior en comparación con el primer modelo. Estos resultados comprueban la importancia de incluir información espectral en el infrarrojo próximo en los estudios de monitoreo ambiental y detección de alteraciones de la cobertura de la tierra en la región amazónica. La composición de bandas CIR muestra mayor sensibilidad a la discriminación de biomasa y detección del vigor de la vegetación en la región del espectro electromagnético del rango del infrarrojo, bien como la fuerte banda de absorción causada por la presencia de clorofila en la región visible, especialmente en la banda del rojo. Al respecto, la composición de bandas CIR, permitió una extracción mayor de características durante el entrenamiento, ya que los objetos de interés que representan cada clase del conjunto de datos se encuentran dominanteamente influenciadas por la alta presencia de vegetación en el contexto espacial.

Se observó que ambos modelos tienden a confundir las clases “pistas de aterrizaje” y “cultivos ilícitos” con la clase “deforestación”, probablemente debido a que el elemento en común entre estas clases es la ausencia de cobertura forestal y la exposición de suelo desnudo en superficie, y en algunos de los recortes de imágenes del conjunto de datos, es prácticamente inevitable que se encuentren en una misma imagen la presencia de estas tres clases. En la Figura 4, se ejemplifican

algunas de las imágenes que el modelo confundió al clasificarlas.

Algo similar ocurre con la clase de “minería ilegal”, al confundirse con la clase “deforestación”, y con la clase “agua”, ya que las actividades de minería en la mayoría de las veces son ejercidas en las proximidades de las redes fluviales o cuerpos de agua, generan fuertes degradaciones de la cobertura vegetal y presentan elementos pictomorfológicos similares (tono, textura, patrón, entre otros). En la Figura 5 se presentan algunos ejemplos.

Posteriormente, para demostrar aplicaciones de uso real y probar la capacidad de generalización de los modelos entrenados, seleccionamos tres áreas naturales protegidas de la región amazónica, que presentan fuertes impactos ambientales por parte de grupos del crimen organizado; Parque Nacional Cerro Yapacana (Organziacion de los Estados Americanos [OEA], 2007), Parque Nacional Natural La Paya (MinAmbiente, 1978) y Floresta Nacional do Amana (*Instituto Chico Mendes de Conservação da Biodiversidade* [ICMBio], 2016).

Siguiendo la metodología aplicada en la sección 4.2, se generaron tres nuevas colecciones de imágenes Sentinel-2 (multiespectrales, georreferenciadas en formato GeoTIFF) con su respectiva enumeración por cada clase, desde el 01/01/2020 hasta el 31/07/2020, correspondientes a cada área

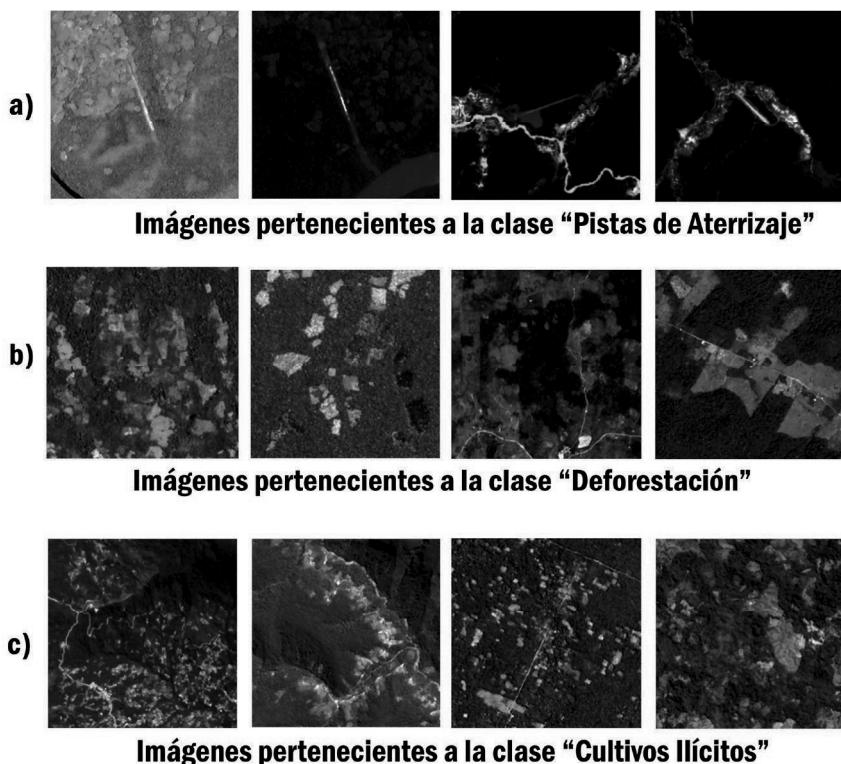


Figura 4. Ejemplo de imágenes clasificadas incorrectamente que tienen en común la clase deforestación. a) algunas de las imágenes pertenecientes a la clase pistas de aterrizaje, presentan en su contexto geográfico pérdida de la cobertura vegetal por causa de la deforestación, cultivos ilícitos y la minería ilegal; b) imágenes pertenecientes a la clase deforestación clasificadas incorrectamente como cultivos ilícitos; c) algunas de las imágenes pertenecientes a la clase cultivos ilícitos que fueron clasificadas incorrectamente ya que poseen también unidades y patrones espaciales correspondientes a la deforestación.

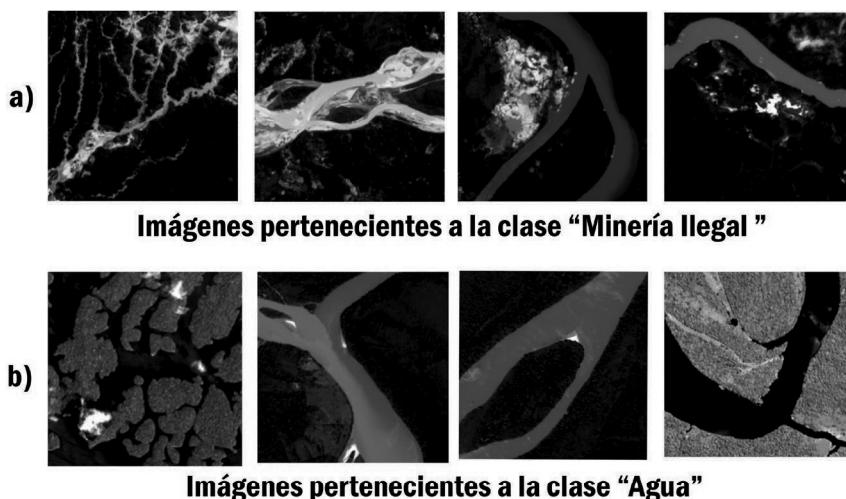


Figura 5. Ejemplo de imágenes clasificadas incorrectamente que tienen en común la clase agua. a) algunas de las imágenes pertenecientes a la clase minería ilegal que por las características propias de esta actividad que es ejercida cerca de las redes fluviales, se clasificaron incorrectamente como la clase agua; b) imágenes pertenecientes a la clase agua clasificadas correctamente.

natural protegida seleccionada, con una cobertura de nubes del 5%. El área del Parque Nacional Yapacana se dividió en 464 recortes de imágenes, El Parque Nacional Natural La Paya en 802 recortes de imágenes y la *Floresta Nacional do Amana* en 1.114 recortes de imágenes, todos los recortes con dimensiones de 256×256 píxeles. Posteriormente se exportaron para almacenamiento local y se derivaron compuestos enumerados de imágenes RGB y CIR en formato JPG.

Seguidamente, los modelos entrenados se aplicaron a los conjuntos de imágenes RGB y CIR (formato JPG) que fueron derivados, obteniendo predicciones que permitieron reconocer diversas áreas afectadas por los CATs, así como también identificar la imagen georreferenciada (formato GeoTIFF) equivalente con la enumeración y obtener las coordenadas geográficas, ya que en la realidad, este es el dato de mayor interés que se desea conocer para promover acciones destinadas a mitigar el impacto ambiental y planificar

Tabla 4. Resultados de las métricas de evaluación del proceso de inferencia, utilizando los conjuntos de imágenes RGB y CIR (formato JPG) que se derivaron.

	DenseNet-201 - Inferencia	
	Primer Modelo RGB	Segundo Modelo CIR
Exactitud Global (<i>Overall Accuracy</i>)	91,74%	93,68%
Precisión (<i>Precision</i>)	91,85%	93,77%
Exhaustividad (<i>Recall</i>)	91,69%	93,68%

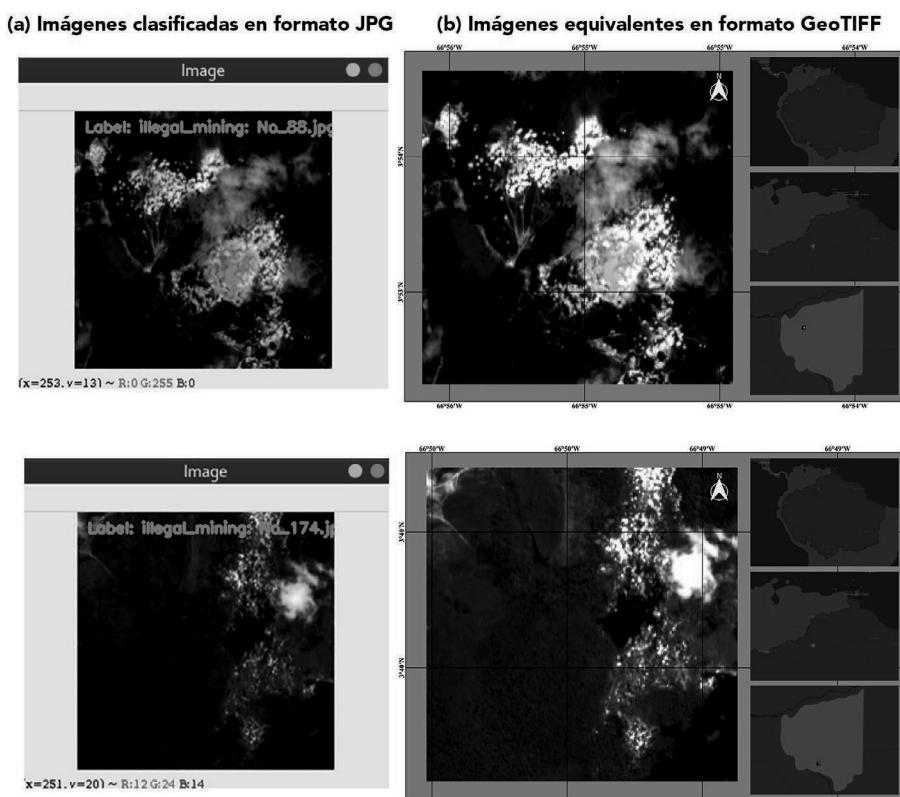


Figura 6. Clasificación y reconocimiento de áreas afectadas por la minería ilegal en el Parque Nacional Yapacana – Venezuela. a) ejemplos de imágenes en formato JPG con su respectiva etiqueta y enumeración clasificadas correctamente como “minería ilegal” durante el proceso de inferencia; b) representación de las imágenes georreferenciadas equivalentes de las imágenes JPG clasificadas. Los mapas de localización representan cartográficamente la región amazónica en América del Sur (polígono verde) y el Parque Nacional Yapacana (polígono rojo) en el estado Amazonas de Venezuela.

operaciones de interdicción terrestre, destinadas a combatir las actividades vinculadas con los CATs y el tráfico ilícito de drogas. Es importante mencionar que *AmazonCRIME* fue construido con imágenes de 2016 a 2019, por lo tanto, este conjunto de imágenes es totalmente desconocido por la red previamente entrenada. En la Tabla 4 se especifican los resultados obtenidos durante el proceso de inferencia.

En la Figura 6, se puede apreciar la clasificación y reconocimiento de áreas afectadas por la minería ilegal en el Parque Nacional Ypacaraí, este se encuentra localizado en el estado Amazonas de Venezuela, tiene un área aproximada de 320.000 ha, con un relieve en forma de meseta, característico de los tepuyes de la región amazónica venezolana (OEA, 2007). Actualmente se

encuentra fuertemente amenazado por la minería ilegal, que es ejercida por grupos armados que han encontrado en este ecosistema una fuente económica para financiar sus actividades vinculadas con el crimen organizado trasnacional (RAISG, 2019).

Otro ejemplo se puede ilustrar en la Figura 7, al aplicar el modelo entrenado se logró obtener predicciones que permitieron reconocer varias áreas potenciales de cultivos ilícitos en el Parque Nacional Natural La Paya. Se encuentra localizado en el departamento del Putumayo al sur de Colombia, posee un área de 422.000 ha, se caracteriza por un sistema hídrico denso y una variada vegetación húmeda tropical. Entre las actividades antrópicas más frecuentes se destaca la extracción de madera, pesca, minería ilegal y cultivos ilícitos (MinAmbiente, 1978; Ministerio de Defensa,

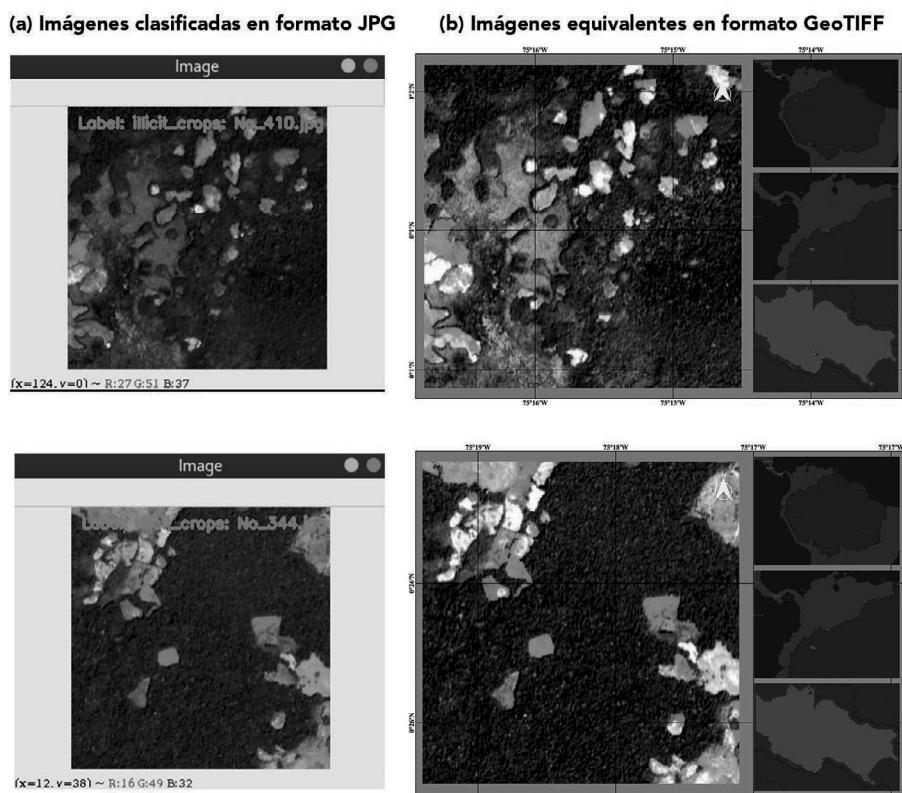


Figura 7. Clasificación y reconocimiento de áreas potenciales de cultivos ilícitos en el Parque Nacional Natural La Paya – Colombia. a) ejemplos de imágenes en formato JPG con su respectiva etiqueta y enumeración clasificadas correctamente como “cultivos ilícitos” durante el proceso de inferencia; b) representación de las imágenes georreferenciadas equivalentes de las imágenes JPG clasificadas. Los mapas de localización representan cartográficamente la región amazónica en América del Sur (polígono verde) y el Parque Nacional Natural La Paya (polígono rojo) en el departamento del Putumayo, Colombia.

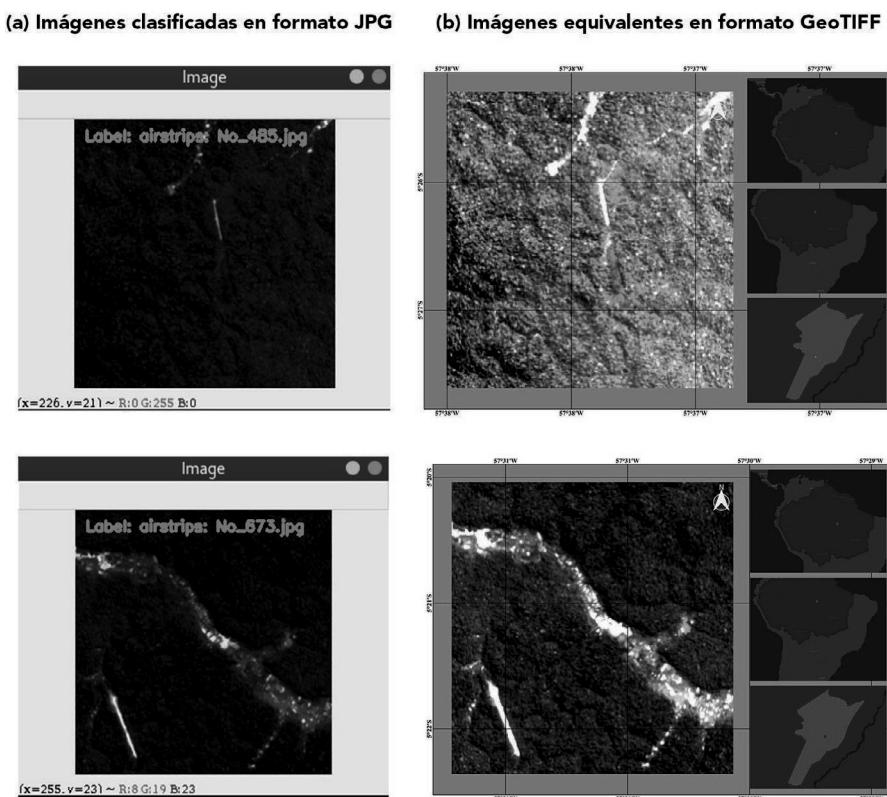


Figura 8. Clasificación y reconocimiento de pistas de aterrizaje en La Floresta Nacional do Amana – Brasil. a) ejemplos de imágenes en formato JPG con su respectiva etiqueta y enumeración clasificadas correctamente como “pistas de aterrizaje” durante el proceso de inferencia; b) representación de las imágenes georreferenciadas equivalentes de las imágenes JPG clasificadas. Los mapas de localización representan cartográficamente la región amazónica en América del Sur (polígono verde) y La Floresta Nacional do Amana (polígono rojo) en el estado de Para, Brasil.

2020), siendo esta área protegida una de las más afectadas por la deforestación ocasionada por grupos armados ilegales dedicados al tráfico ilícito de drogas.

La Floresta Nacional do Amana se encuentra en el estado de Para, Brasil, cuenta con un área aproximada de 540.417 ha, se caracteriza por tener una vegetación densa, extensa hidrografía y una variada diversidad de flora y fauna. Se creó con el objeto de ser un área protegida con uso sostenible de recursos naturales, sin embargo, la expansión de la minería ilegal y la deforestación, son las principales amenazas en esta unidad de conservación ambiental (ICMBio., 2016; Oliveira, 2018). En este sentido, al aplicar el modelo entrenado, las predicciones lograron identificar áreas afectadas por la minería de recursos naturales, así como también pistas de aterrizaje con características

rudimentarias. En este particular, al superponer los resultados con los datos geoespaciales de la ANAC, se logró identificar una pista de aterrizaje que no coincide con los registros oficiales. En la Figura 8, se muestran algunos ejemplos.

6. Conclusiones

En este documento abordamos el desafío de clasificar imágenes en la selva amazónica. Presentamos un nuevo conjunto de datos construido a partir de imágenes satelitales Sentinel-2, las cuales son de libre acceso y proporcionadas por el programa Copernicus de la Unión Europea. El conjunto de datos consta de 6 clases, 5.000 imágenes por clase, para un total de 30.000 imágenes multiespectrales de 13 bandas, nivel 1C, etiquetadas, enumeradas y georreferenciadas en formato

GeoTIFF. Adicionalmente ofrecemos una versión derivada, con combinaciones de banda RGB en formato JPG, empleada para entrenar la arquitectura *DenseNet-201*. Entre las principales contribuciones de este trabajo, presentamos el primer conjunto de datos destinado a generar aplicaciones de inteligencia artificial geoespacial, para la clasificación y detección de áreas vinculadas con crímenes ambientales transnacionales en la selva amazónica a gran escala, ya que de acuerdo a la revisión de los trabajos relacionados, los conjuntos de datos disponibles están dirigidos principalmente para aplicaciones agrícolas, uso y cobertura del suelo y detección de elementos naturales y culturales comunes, siendo escasa la disponibilidad de conjuntos de datos de referencia para aplicaciones del dominio de interés de esta investigación. Destacamos la importancia de crear nuevos conjuntos de datos que prioricen la representación geográfica de la región amazónica, ya que la mayoría de los conjuntos de datos de imágenes de satélite disponibles públicamente, están sesgados hacia otras regiones del mundo, lo que limita la aplicación de la GeoAI en la Amazonía. Entrenamos y analizamos el rendimiento de las bandas espectrales RGB (4,3,2) y CIR (8,4,3), basado en recortes de imágenes y tareas de clasificación de escenas. Como resultado la combinación de bandas CIR obtuvo un rendimiento general superior en la calidad de los resultados, en comparación con la combinación de bandas RGB. Demostramos la capacidad de generalización de los modelos entrenados con el conjunto de datos *AmazonCRIME* y el potencial de uso para aplicaciones reales, al ser aplicados en nuevas imágenes de satélite, correspondientes a áreas de la región amazónica fuertemente amenazadas por el crimen organizado transnacional.

Esperamos que *AmazonCRIME* fomente el desarrollo de futuras investigaciones que permitan promover aplicaciones e iniciativas tanto de alcance local como regional, destinadas a resguardar los activos ambientales de tan importante región estratégica. La fuerte relación entre la minería ilegal, la deforestación con otras economías ilegales como el tráfico ilícito de drogas, se convierte en una amenaza que requiere de acciones urgentes, de enfoques integrales y de herramientas tecnológicas como la GeoAI, para restablecer el equilibrio ecológico en la selva tropical más grande del mundo.

7. Agradecimientos

Agradecemos al Programa de Posgraduación en Ciencias Geodésicas de la Universidad Federal de Paraná y el apoyo financiero al Consejo Nacional de Desarrollo Científico y Tecnológico de Brasil (CNPq) (190032/2017-0).

8. Referencias

- Abdani, S.R., & Zulkifley, M.A. 2019. Densenet with spatial pyramid pooling for industrial oil palm plantation detection. In *2019 International Conference on Mechatronics, Robotics and Systems Engineering*. 134-138. <https://doi.org/10.1109/MoRSE48060.2019.8998735>
- Basu, S., Ganguly, S., Mukhopadhyay, S., DiBiano, R., Karki, M., & Nemani, R. 2015. DeepSat - A Learning framework for Satellite Imagery. *Association for Computing Machinery*, 37, 1-10. <https://doi.org/10.1145/2820783.2820816>
- Bingham, H., Bignoli, D., Lewis, E., MacSharry, B., Burgess, N., Visconti, P., Kingston, N. 2019. Sixty years of tracking conservation progress using the World Database on Protected Areas. *Nature Ecology & Evolution*, 3, 737–743. <https://doi.org/10.1038/s41559-019-0869-3>
- Boguszewski, A., Batorski, D., Jankowska, N., Zambrzycka, A., & Dziedzic, T. 2020. LandCover.ai: Dataset for Automatic Mapping of Buildings, Woodlands and Water from Aerial Imagery. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 1102-1110. <https://doi.org/10.1109/CVPRW53098.2021.00121>
- CAF (Banco de Desarrollo de América Latina). 2019. *La riqueza natural de la Amazonía como base del desarrollo sostenible regional*. Último acceso: 01 de Noviembre, 2021, de <https://www.caf.com/es/conocimiento/visiones/2019/09/la-riqueza-natural-de-la-amazonia-como-base-del-desarrollo-sostenible-regional/>.
- Camps-Valls, G., Tuia, D., Zhu, X.X., & Reichstein, M. (Eds.). 2021. *Deep learning for the Earth Sciences: A comprehensive approach to remote sensing, climate science and geosciences*. John Wiley & Sons. <https://doi.org/10.1002/9781119646181>
- Cheng, G., Han, J., & Lu, X. 2017. Remote Sensing Image Scene Classification: Benchmark and State of the Art. *Proceedings of the IEEE*, 105(10), 1865-1883. <https://doi.org/10.1109/JPROC.2017.2675998>

- Chiu, M.T., Xu, X., Wei, Y., Huang, Z., Schwing, A.G., Brunner, R.,... & Shi, H. 2020. Agriculture-vision: A large aerial image database for agricultural pattern analysis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2828-2838. <https://doi.org/10.1109/CVPR42600.2020.00290>
- Clark, R. 2020. *Geospatial Intelligence. Origins and Evolution*. Washington, DC: Geogertown University Press.
- Coorey, R. 2018. *The Evolution of Geospatial Intelligence. Australian Contributions to Strategic and Military Geography. Advances in Military Geosciences*. Springer, Cham. https://doi.org/10.1007/978-3-319-73408-8_10
- Demir, I., Koperski, K., Lindenbaum, D., Pang, G., Huang, J., Basu, S.,... & Raskar, R. 2018. Deepglobe 2018: A challenge to parse the earth through satellite images. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, 172-181. <https://doi.org/10.1109/CVPRW.2018.00031>
- ESA (European Space Agency) 2015. *Sentinel -2 User Handbook*. ESA Standard Document.
- European Commission. 2015. *Copernicus. Europe's eyes on Earth*. Brussels: Publications Office of the European Union.
- EUROPOL (European Union Agency for Law Enforcement Cooperation). 2011. *EU Organised Crime Threat Assessment. OCTA 2011*. EUROPOL Public Information.
- Exército Brasileiro. 2018. *Operação Curare IX - Interdição de pista de pouso clandestina*. Último acceso: 16 de Febrero, 2021, de http://www.eb.mil.br/web/noticias/noticiario-do-exercito/-/asset_publisher/MjaG93KcunQI/content/no-contexto-da-operacao-curare-ix-1-brigada-infantaria-de-selva-realiza-interdicao-de-pista-de-pouso-clandestina-/8357041.
- GEE (Google Earth Engine). *Sentinel-2*. Último acceso 05/11/2021, de <https://developers.google.com/earth-engine/datasets/catalog/sentinel-2>.
- Global Initiative Against Transnational Organized Crime. 2016. *Organized Crime and Illegally Mined Gold in Latin America*. <https://globalinitiative.net/analysis/organized-crime-and-illegally-mined-gold-in-latin-america>
- Global Initiative Against Transnational Organized Crime. 2021. Environmental crime: *The not-so-hidden obstacle to combat climate change*. Último acceso: 01 de Noviembre, 2021, de <https://globalinitiative.net/analysis/environmental-crime-climate-change/>.
- Gore, M.L., Braszak, P., Brown, J., Cassey, P., Duffy, R., Fisher, J.,... & White, R. 2019. Transnational environmental crime threatens sustainable development. *Nature Sustainability*, 2(9), 784-786. <https://doi.org/10.1038/s41893-019-0363-6>
- Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. 2017. Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote sensing of Environment*, 202, 18-27. <https://doi.org/10.1016/j.rse.2017.06.031>
- Helber, P., Bischke, B., Dengel, A., & Borth, D. 2019. Eurosat: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(7), 2217-2226. <https://doi.org/10.1109/JSTARS.2019.2918242>
- Hoeser, T., & Kuenzer, C. 2020. Object detection and image segmentation with deep learning on earth observation data: A review-part i: Evolution and recent trends. *Remote Sensing*, 12(10), 1667. <https://doi.org/10.3390/rs12101667>
- Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K.Q. 2017. Densely connected convolutional networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 4700-4708. <https://doi.org/10.1109/CVPR.2017.243>
- ICMBio. 2016. Plano de Manejo Floresta Nacional do Amana. Último acceso: 10 de Marzo, 2021, de <https://www.icmbio.gov.br/portal/unidadesdeconservacao/biomas-brasileiros/amazonia/unidades-de-conservacao-amazonia/1955-flona-do-amana>.
- INPE (Instituto Nacional de Pesquisas Espaciais). 2020. *TerraBrasilis*. Último acceso: 11 de Enero, 2021, de <http://terrabrasilis.dpi.inpe.br/en/home-page/>.
- Insight Crime. 2020. *Narcovuelos y pistas clandestinas en al menos seis estados de Venezuela*. Último acceso: 11 de Enero, 2021, de <https://es.insightcrime.org/noticias/noticias-del-dia/narcovuelos-seis-estados-venezuela/>.
- INTERPOL (International Criminal Police Organization). 2018. *World atlas of illicit flows*. Último acceso: 01 de Noviembre, 2021, de <https://globalinitiative.net/wp-content/uploads/2018/09/Atlas-Illicit-Flows-FINAL-WEB-VERSION-copia-compressed.pdf>.
- Janowicz, K., Gao, S., McKenzie, G., Hu, Y., & Bhaduri, B. 2020. GeoAI: spatially explicit artificial intelligence techniques for geographic knowledge discovery and beyond. *International Journal of Geographical Information Science*, 34(4), 625-636. <https://doi.org/10.1080/13658816.2019.1684500>

AmazonCRIME: un conjunto de datos y punto de referencia de Inteligencia Artificial Geoespacial para la clasificación de áreas potenciales vinculadas a Crímenes Ambientales Transnacionales en la Selva Amazónica

- Khan, M.A., Hussain, N., Majid, A., Alhaisoni, M., Syed Ahmad Chan, B., Kadry, S., Yu-Dong, Z. 2021. Classification of positive COVID-19 CT scans using deep learning. *Computers, Materials, & Continua*, 66(3), 2923-2938. <https://doi.org/10.32604/cmc.2021.013191>
- Koh, J.C., Spangenberg, G., & Kant, S. 2021. Automated Machine Learning for High-Throughput Image-Based Plant Phenotyping. *Remote Sensing*, 13(5), 858. <https://doi.org/10.3390/rs13050858>
- Kussul, N., Lavreniuk, M., Skakun, S., & Shelestov, A. 2017. Deep learning classification of land cover and crop types using remote sensing data. *IEEE Geoscience and Remote Sensing Letters*, 14(5), 778-782. <https://doi.org/10.1109/LGRS.2017.2681128>
- LeCun, Y., Bengio, Y., & Hinton, G. 2015. Deep learning. *nature*, 521(7553), 436-444. <https://doi.org/10.1038/nature14539>
- Letitia, A. 2013. Activity based intelligence: Understanding the unknown. *The intelligencer: Journal of US intelligence studies*, 20(2), 7-16.
- López-Jiménez, E., Vasquez-Gomez, J. I., Sanchez-Acevedo, M. A., Herrera-Lozada, J. C., & Uriarte-Arcia, A. V. 2019. Columnar cactus recognition in aerial images using a deep learning approach. *Ecological Informatics*, 52, 131-138. <https://doi.org/10.1016/j.ecoinf.2019.05.005>
- Lowenthal, M. 2020. *Intelligence. From secrets to policy*. CQ. Press.
- Lycia, B., Abdenur, A., Pellegrino, A., Porto, C., & Brasil, L. 2019. *Los delitos Ambientales en la Cuenca del Amazonas: el rol del crimen organizado en la minería*. El Pacto. Europa Latinoamérica. Programa de Asistencia contra el Crimen Transnacional Organizado. Último acceso: 11 de Mayo, 2020, de <https://www.elpacito.eu/wp-content/uploads/2019/05/Los-Delitos-Ambientales-en-la-Cuenca-del-Amazonas-comprimido.pdf>.
- Ma, L., Liu, Y., Zhang, X., Ye, Y., Yin, G., & Johnson, B. A. 2019. Deep learning in remote sensing applications: A meta-analysis and review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 152, 166-177. <https://doi.org/10.1016/j.isprsjprs.2019.04.015>
- MinAmbiente. Parques Nacionales Naturales de Colombia. 1978. Plan de Manejo del Parque Nacional Natural La Paya. Último acceso: 10 de Marzo, 2021, de <https://www.parquesnacionales.gov.co/portal/wp-content/uploads/2020/10/plan-de-manejo-pnn-la-paya.pdf>.
- Ministerio de Defensa. 2020. *Medio Ambiente. Defensa*. Último acceso: 10 de Marzo, 2021, de https://www.mindefensa.gov.co/irj/go/km/docs/Mindefensa/Documentos/descargas/Documentos_Descargables/espanol/Medio%20Ambiente.pdf.
- Nogueira, K., Dos Santos, J.A., Fornazari, T., Silva, T.S.F., Morellato, L.P., & Torres, R.D.S. 2016. Towards vegetation species discrimination by using data-driven descriptors. In *2016 9th IAPR Workshop on Pattern Recognition in Remote Sensing (PRRS)* (pp. 1-6). IEEE. <https://doi.org/10.1109/PRRS.2016.7867024>
- OEA (Organización de los Estados Americanos). 2007. *Yapacana National Park*. BioParques: Parkswatch Program. Último acceso: 10 de Marzo, 2021, de [https://www.oas.org/dsd/AAPAD2/Docs/\(iii\)%20Yapacana%20NP%20Special%20Report%20\(Venezuela\).pdf](https://www.oas.org/dsd/AAPAD2/Docs/(iii)%20Yapacana%20NP%20Special%20Report%20(Venezuela).pdf).
- Oliveira, D. 2018. *Atividade garimpeira na região do Tapajós (PA): o caso na Flona do Amana*. Monografia, Instituto CEUB de Pesquisa e Desenvolvimento, Centro Universitário de Brasília). <https://repositorio.uniceub.br/jspui/handle/235/11514>.
- openAIP. 2021. *Worldwide aviation database*. Último acceso: 5 de Enero, 2021, de <http://www.openaip.net/>.
- Penatti, O.A., Nogueira, K., & Dos Santos, J.A. 2015. Do deep features generalize from everyday objects to remote sensing and aerial scenes domains? In *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, 44-51. <https://doi.org/10.1109/CVPRW.2015.7301382>
- Pennsylvania State University. 2020. GEOINT MOOC. Último acceso 05/11/2021, de <https://www.e-education.psu.edu/geointmooc/node/1989>.
- Planet Labs. 2017. *Planet: Understanding the Amazon from Space*. Último acceso: 08 de Enero, 2021, de <https://www.kaggle.com/c/planet-understanding-the-amazon-from-space>.
- QGIS Development Team. *QGIS. A Free and Open Source Geographic Information System*. Último acceso: 08 de Enero, 2021, de <https://qgis.org/en/site/>.
- RAISG (Red Amazónica de Información Socioambiental Georreferenciada). 2012. *Amazonía Bajo Presión*. Último acceso: 14 de Enero, 2021, de www.raisg.socioambiental.org.
- RAISG (Red Amazónica de Información Socioambiental Georreferenciada). 2018a. *Amazonía saqueada: el primer mapa de minería ilegal en el pulmón del mundo*. 2018. Último acceso: 14 de Enero, 2021, de <https://www.amazoniasocioambiental.org/es/radar/mapa-inedito-indica-epidemia-de-garimpo-ilegal-na-panamazonia/>.